金融計算書面報告

基於 ETH 選擇權隱含波動率曲面之 QDA 交易策略

110191019 鍾侑廷

一、研究動機與摘要

量化交易的核心是速度，但要從海量的期權數據中提取有價值的訊號，可能會有計算延遲。培養交易策略也需要時間及資金成本，因此希望能有視覺化工具幫助投資者能快速地做出決策。為此本研究旨在利用 Ethereum (ETH) 選擇權市場的隱含波動率資訊，預測 ETH 現貨價格在未來 4 小時內的走勢。結合教授期中和期末報告給予的回饋，透過 Wing Model 萃取波動率曲面的偏斜與曲率特徵，並結合 ATM IV，使用二次判別分析進行分類預測。最終透過信心門檻與停損機制優化策略，並與買入持有策略進行績效對比。

二、方法

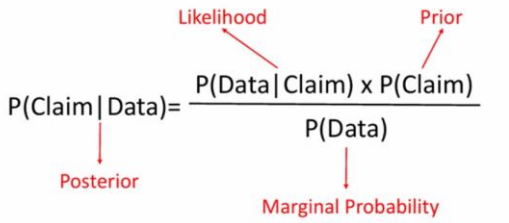
本研究採取監督式學習，主要方法論包含以下：

1. Wing Model

不直接使用原始 IV 數據，而是利用 Wing Model 對選擇權的價外隱含波動率進行二次多項式擬合。透過最小平方法提取反映市場情緒的參數。

2. 分類模型 - 二次判別分析 (QDA)

Quadratic Discriminant Analysis(QDA)源於貝氏定理。其核心公式為：



QDA 是一種分類演算法，透過學習各類別的統計特徵來判斷新資料點的歸屬。它假設每個類別的資料都服從獨立的多變量常態分佈。模型會為每個類別計算其獨特的中心點 (Mean) 和形狀 (Covariance Matrix)。

模型計算在特定類別下觀察到資料的機率 。再利用貝氏定理計算資料屬於每個類別的事後機率，進而做出分類判斷。與 LDA 不同，QDA 允許每個類別擁有各自獨立、不相同的共變異數矩陣。這使得決策邊界能夠是曲線（二次方程式），而非直線，能適應更複雜的資料分佈，因此本研究使用 QDA 作為核心預測模型。而標籤會根據 ETH 現貨在未來 4 小時的報酬率分成上漲、盤整、下跌三種類別，以捕捉短期市場動能。

三、文獻回顧

Deep Learning Option Pricing with Market Implied Volatility Surfaces Ding、Lu 與 Cheung（2025）的研究深入探討了深度學習在選擇權定價中的應用，旨在解決傳統參數模型與數值方法的侷限性。傳統的 Black-Scholes 框架假設波動率為常數且資產價格服從對數常態分佈，然而真實市場中普遍存在波動率微笑（Volatility Smiles）、期限結構與跳躍等現象，這使得模型必須進行調整才能符合現實。雖然蒙特卡羅模擬或有限差分法等數值方法能處理奇異選擇權，但在處理從流動性佳的歐式選擇權校準出的高維度市場隱含波動率曲面時，其計算密集度極高，難以擴展至即時定價與風險評估。現有的機器學習定價方法雖然提供了數據驅動的非參數替代方案，但通常使用平坦波動率（Flat Volatility），未能充分考量實際市場數據中觀察到的波動率曲面複雜性。為此，該研究提出了一種基於變分自動編碼器（Variational Autoencoder, VAE）的框架，將高維度的波動率曲面壓縮至低維度的潛在空間（Latent Space），並結合多層感知機（MLP）進行定價。這種方法不僅克服了參數化模型的限制，更提供了一種無需依賴高成本數值求解器的快速定價途徑，證實了透過降維技術捕捉波動率曲面幾何特徵在金融定價上的有效性。

Deep Learning from Implied Volatility Surfaces Kelly、Kuznetsov、Malamud 與 Xu（2023）的研究則聚焦於如何利用隱含波動率曲面預測股票橫截面收益，並探討了資產定價中的「因子動物園（Factor Zoo）」現象。選擇權隱含波動率曲面包含了關於狀態相依風險溢酬（State-contingent risk premia）與未來收益分佈的重要資訊，過去文獻多透過建構如波動率水平、斜率與曲率等線性特徵來捕捉這些訊號。然而，該研究不預先設定特徵，而是利用卷積神經網絡（CNN）直接從原始 IV 曲面影像中提取非線性特徵。研究發現，僅依賴少數線性特徵，如傳統的斜率或偏度，並不足以捕捉市場的預測資訊，這挑戰了傳統經濟學模型中的稀疏性假設。相反地，該研究提出了複雜性的優點，指出在

有限的數據下，高度複雜的非線性模型，如大型 CNN 集合，能更有效地提取未被傳統因子跨越的資訊。這項文獻為本研究不直接使用原始數據，而是試圖透過模型捕捉曲面複雜特徵的作法提供了理論支持，說明了隱含波動率曲面的幾何形狀確實蘊含了對未來價格變動的預測能力。

Using Quadratic Discriminant Analysis To Optimize An Intraday Momentum Strategy Coleman（2018）的文章探討了如何利用二次判別分析（QDA）來優化日內動能交易策略，其核心在於利用機器學習消除交易中的認知偏差並提升客觀性。在量化交易中，預測下一個價格方向屬於分類問題，而線性判別分析（LDA）與 QDA 均是常見的分類算法。兩者皆假設數據類別來自高斯分佈，並利用貝氏定理估計參數，但關鍵差異在於對共變異數矩陣的假設。LDA 假設所有類別共享同一個共變異數矩陣，這在變異結構複雜的金融市場中可能導致模型偏差過高；相比之下，QDA 放寬了此限制，允許每個類別擁有獨立的共變異數矩陣。雖然 QDA 因需要估計更多參數而計算成本較高且可能增加變異，但在類別間波動結構顯著不同時，其靈活性使其表現優於 LDA。該文獻展示了如何利用 QDA 作為過濾機制，通過預測並剔除可能虧損的交易來優化策略的勝率與盈虧比，這為本研究選擇 QDA 作為預測模型以處理上漲、下跌、盤整不同市場狀態下的非線性特徵提供了實務上的方法論依據。

四、運作細節

1.資料載入與清理

使用 pandas 載入 eth_options_iv.csv 數據集，此數據由教授提供，數據為 1 小時間隔，日期從 2023-09-16 到 2024-05-31。首先將時間欄位 (hr_time) 轉換為 datetime 格式並進行排序，確保時間序列的正確性。

2.市場狀態標籤

為了進行監督式學習，定義了三種市場狀態。利用未來 4 小時的價格 (Future_S) 與當前價格 (spot) 計算報酬率。分類邏輯如下：

- 上漲 (Class 1, Up): 報酬率 > 0.15% (0.0015)。
- 下跌 (Class 3, Down): 報酬率 < -0.15% (-0.0015)。
- 盤整 (Class 2, Neutral): 報酬率介於 -0.15% 與 0.15% 之間。

此門檻設置是為了讓標籤分佈更加平衡，避免模型過度傾向於預測盤整。

3. Wing Model 參數萃取

為了捕捉市場情緒，因此不直接使用原始 IV 數據，而是對每一筆觀測值的 Strike Price (K) 與 OTM IV 進行二次多項式擬合（Wing Model Calibration）。

針對每個時間點，篩選出有效的 OTM IV 數據，並建構矩陣 A 進行最小平方法運算：

$$IV = \beta_0 + \beta_1 K + \beta_2 K^2$$

其中 β_1 (Skew) 反映市場對漲跌的偏斜看法。而 β_2 (Curvature) 是波動率微笑的彎曲程度，反映市場對極端風險的定價。

為了補足 Wing Model 形狀參數所缺失的波動率水平資訊，本研究將 ATM IV 放入模型，從而讓機器學習模型獲得更完整的市場觀點。

ATM IV (At-The-Money Implied Volatility) 指的是價平隱含波動率。它代表的是在所有可選的履約價（Strike Price）中，距離當前現貨價格（Spot Price）最近的那一個履約價所對應的隱含波動率。

計算方式為首先從每一行數據中提取當前的現貨價格 row['spot']，以及經過清理後的有效履約價陣列 K_clean 和對應的價外隱含波動率陣列 otm_iv_clean。之後會計算所有履約價與當前現貨價格之間的絕對差值。接著，使用 .argmin() 函數找到這個差值最小的位置，即距離現貨價格最近的履約價的索引。最後利用上述找到的索引 idx_atm，從隱含波動率陣列中取出對應的數值，這就是 atm_iv

每一筆資料最終提取β_1、β_2及 ATM IV 這三個關鍵特徵作為 QDA 模型的輸入。之後使用 StandardScaler 對特徵進行標準化，確保不同量級的特徵不會影響模型權重。

4. 二次判別分析 (QDA) 模型訓練

將數據的前 70% 劃分為訓練集，後 30% 作為測試集，用於後續的回測驗證。QDA 假設各類別數據服從多變量常態分佈，但允許各類別擁有獨立的共變異數矩陣 (class_covs)，因此計算了各類別的平均值向量 (class_means) 與先驗機率 (class_priors)。為了直觀理解決策邊界，研究中繪製了二維分類圖。

由於模型是三維特徵，繪圖時將 ATM IV 固定在平均值，僅展示 β_1 與 β_2 對分類的影響。

5. 策略回測與績效分析

本研究運用了三種策略進行回測，目的是希望可以獲得較高的報酬率，因此每次的策略都有進行優化，最終進行三種策略的比較。

5.1 基礎回測邏輯

在測試集上進行預測，並根據混淆矩陣 (Confusion Matrix) 評估準確率。交易邏輯設定為當預測 Up (1)時就做多，以獲取市場報酬。若預測 Down (3)就做空，獲取反向報酬。若是預測 Neutral (2)則觀望 (Return = 0)。為防止極端異常值影響回測真實性，將單次報酬率限制在 ±5% 以內。

5.2 策略優化 I：信心門檻 (Confidence Threshold)

基礎策略可能在訊號微弱時頻繁交易，因此引入信心機制，設定門檻為 60%。此策略的邏輯是只有當模型對 Up 或 Down 的預測機率大於 60% 時才進場，否則強制視為 Neutral。透過過濾低信心訊號，旨在提升勝率並減少不必要的交易成本。

5.3 策略優化 II：動態停損 (Dynamic Stop Loss)

為了控制下檔風險，加入停損機制，設定停損點為 -1.5%。當實際虧損超過 1.5% 時，強制平倉，將該次交易虧損鎖定在 -1.5%。希望達成避免單次錯誤預測造成資產大幅回撤的效果。

五、成果與洞察

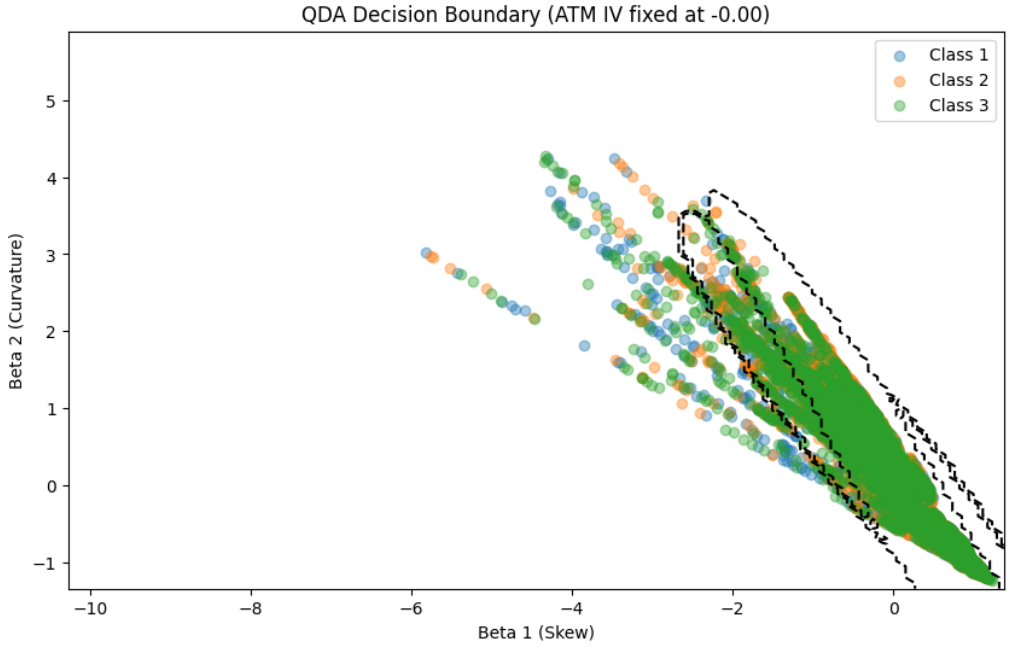
本研究依照實驗流程，依序展示了 QDA 模型的訓練結果、預測準確度評估，以及三階段交易策略的績效演進。

5.1 QDA 模型訓練與決策邊界

在完成 Wing Model 的特徵提取後，我們將數據標準化並輸入 QDA 模型進行訓練。為了直觀呈現模型如何區分上漲 (Class 1)、盤整 (Class 2) 與下跌 (Class 3)，我們將第三維度特徵（ATM IV）固定在平均值，約 -0.00 標準差位置，繪製了二維決策邊界圖。

從圖中可以觀察到藍色為上漲、橙色為盤整、綠色為下跌，並非由直線劃分，而是呈現圓弧狀或拋物線狀的曲線邊界。這證實了 QDA 模型放寬了「共用共變異數矩陣」的假設，允許各類別擁有獨立的共變異數，從而能更靈活地捕捉隱含波動率曲面特徵與市場方向之間的非線性關係。

圖中顯示各類別樣本點在特徵空間中存在一定程度的重疊，這反映了金融市場數據的高雜訊特性，也暗示單純依靠幾何特徵進行完全準確的分類具挑戰性。



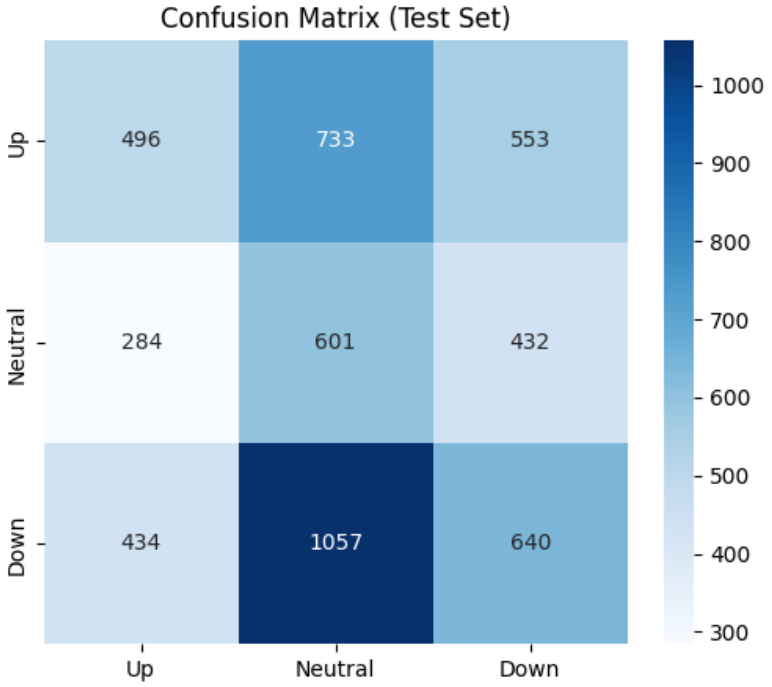
圖中的兩個軸線是市場情緒的量化指標：

軸線	參數	金融意義	行為傾向
X 軸	β_1 (Skew / 斜率)	風險厭惡程度：負值越大 (越往左)，表示市場越擔心下跌	負斜率大 (左)：熊市/下跌恐慌情緒高。
Y 軸	β_2(Curvature / 曲率)	尾部風險溢價：數值越大 (越往上)，表示市場對極端事件的預期和溢價越高。	高曲率 (上)：對極端尾部事件的避險需求高。

類別	金融意義	交易訊號
Class 1 (上漲)	市場仍處於下跌恐慌中，但價格已開始反轉，顯示恐慌情緒可能過度。	買入
Class 2 (盤整)	波動率曲面形狀最穩定，市場情緒一致且平靜	中性/觀望
Class 3 (下跌)	市場的 Skew 並不是最極端的。這可能代表下跌是突發性的，或是恐慌情緒正快速消退	賣出/避險

5.2 模型預測能力評估

我們在測試集上評估了模型的分類能力，混淆矩陣（Confusion Matrix）展示了模型預測標籤與真實市場狀態的對應情況。矩陣的對角線數值代表預測正確的次數。透過觀察矩陣，我們能評估模型對特定類別，如「下跌」或「盤整」，是否有預測偏誤。非對角線的數值揭示了預測錯誤的類型。例如，將下跌誤判為上漲屬於嚴重的型一錯誤，這將在回測中導致直接的交易虧損。此矩陣為後續引入「信心門檻」提供了數據支持，即需要過濾掉那些模型模稜兩可的預測。




```
--- 回測報告 ---
準確率: 33.21%
              precision    recall  f1-score   support

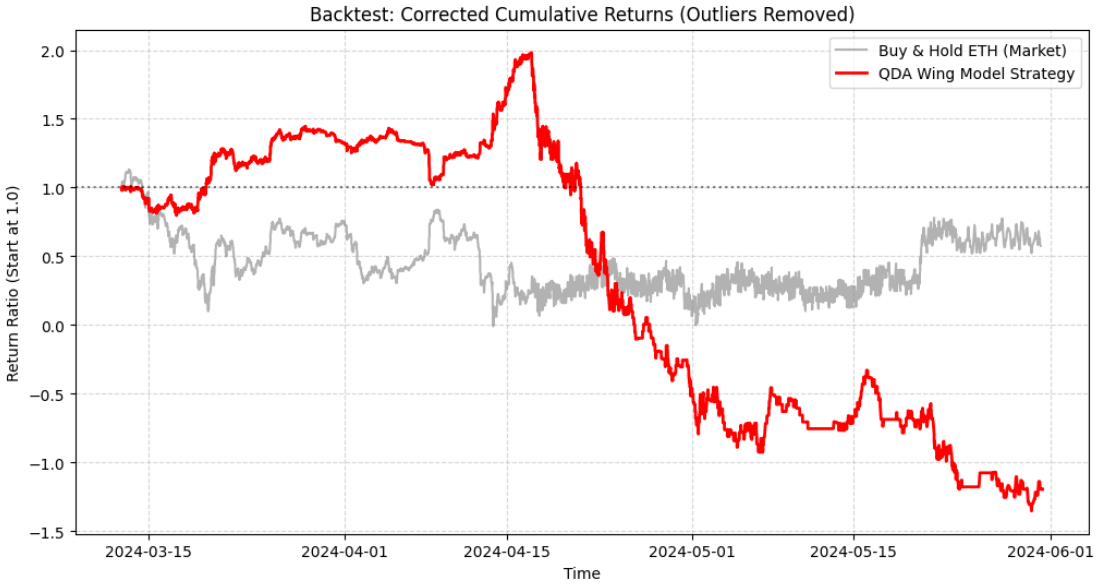
          Up       0.41      0.28      0.33      1782
     Neutral       0.25      0.46      0.32      1317
        Down       0.39      0.30      0.34      2131

    accuracy                           0.33      5230
   macro avg       0.35      0.35      0.33      5230
weighted avg       0.36      0.33      0.33      5230
```

5.3 策略一：基礎 QDA Wing Model 策略

第一階段回測採用最基礎的交易邏輯，若預測為上漲則做多，預測為下跌則做空，預測為盤整則空手。紅色曲線代表策略累積報酬，灰色曲線代表 ETH 買入持有（Buy & Hold）的市場基準。從圖表可見，基礎策略雖然能捕捉到部分波段，但在市場震盪或趨勢不明顯時，資金曲線出現了劇烈波動，甚至在大

回撤期間表現劣於單純持有策略,。程式碼中我們限制了單次報酬率在 ±5% 以內，以排除數據錯誤造成的異常值，確保回測結果的真實性。

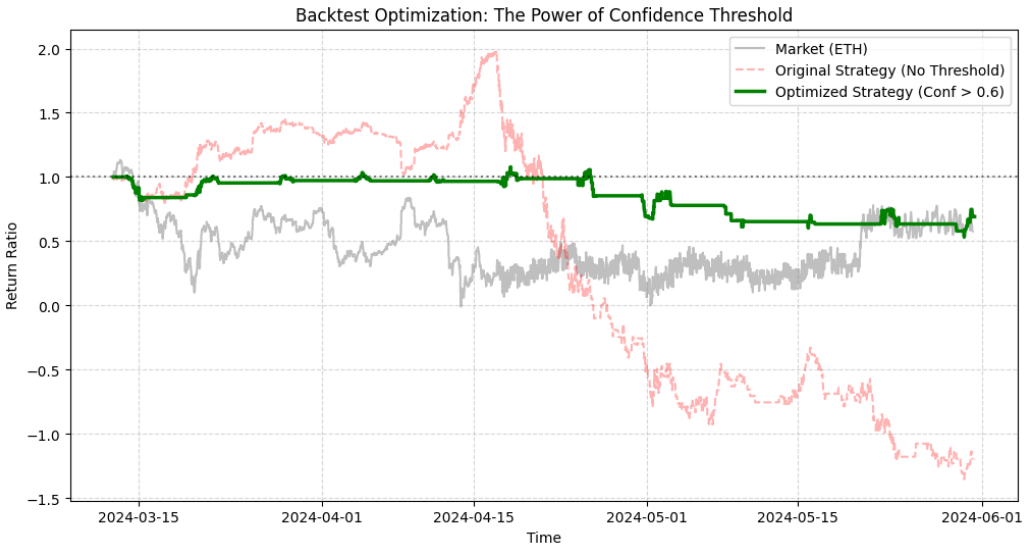


測試期間總收益率: -219.37%

策略勝率 (排除觀望次數): 48.80%

5.4 策略二：信心門檻優化

針對基礎策略頻繁交易與誤判的問題，我們引入了 60% 的信心門檻。只有當 QDA 模型對某個方向（漲或跌）的預測機率超過 60% 時才進場，否則強制視為觀望（Neutral）。綠色曲線顯示，相較於原始策略（粉紅色虛線），加入信心門檻後的策略顯著減少了交易次數，因為曲線中出現更多水平線段，代表空手觀望期。這種機制有效地過濾了許多低信心的雜訊交易，使得資金曲線變得更加平滑且穩健，避免了原始策略在震盪市中不斷虧損的情況。

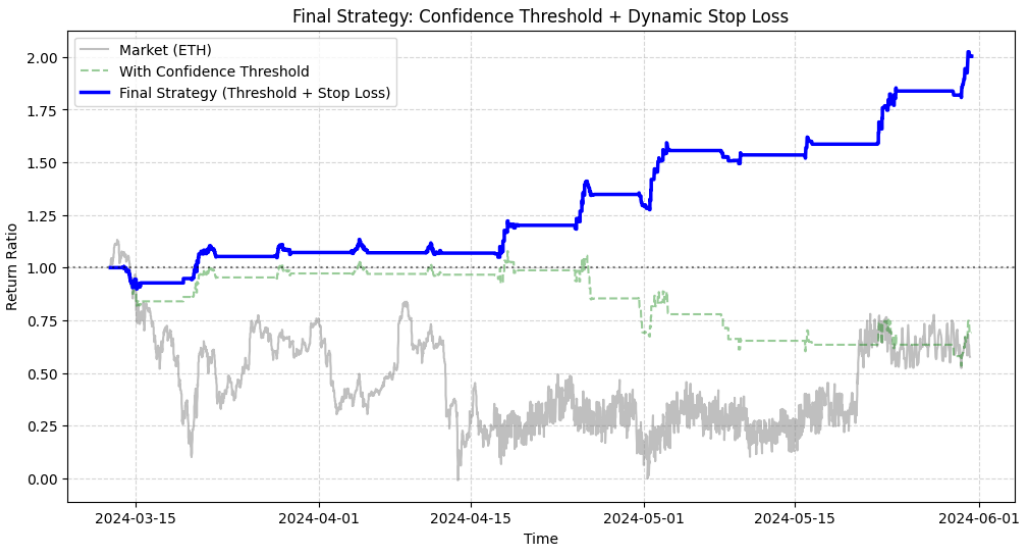


原始策略收益: -219.37% (交易次數: 2839)

優化策略收益: -30.84% (交易次數: 353)

5.5 策略三：結合信心門檻與動態停損

為了進一步控制下檔風險，我們在信心門檻的基礎上加入了動態停損機制。當單筆交易的虧損超過 1.5% 時，強制平倉出場。圖中的藍色曲線展示了最終策略的表現。相較於僅有信心門檻的策略（綠色虛線），最終策略在市場發生不利反轉時能迅速截斷虧損。這使得策略在保留了捕捉大趨勢能力的同時，大幅降低了最大回撤。圖表顯示最終策略的累積收益率顯著優於市場基準（灰色線），證明了結合「Wing Model 特徵提取」、「QDA 非線性分類」與「嚴格風控（信心+停損）」的複合策略，在 ETH 選擇權與現貨交易中具有獲取超額報酬的潛力。



信心門檻策略收益: -30.84%

加入停損後最終收益: 100.32%

結論

報告最終證實，雖然單純依靠 Wing Model 特徵與 QDA 模型不足以直接獲利，但若結合「波動率曲面特徵提取」、「QDA 非線性分類」以及「嚴格的風險管理（信心過濾 + 停損）」，此複合策略在 ETH 選擇權與現貨交易中具有獲取超額報酬的潛力。且 Wing Model 特徵提取的延遲將獲得顯著降低，使其適用於實時交易環境。

程式碼連結：
https://colab.research.google.com/drive/1Y15cgieIpbkXxBtO0aGziz3nhPJHAYN-?usp=sharing